



ACADEMIA DE STUDII ECONOMICE DIN BUCUREȘTI
FACULTATEA DE CONTABILITATE ȘI INFORMATICĂ DE
GESTIUNE

LUCRARE DE LICENȚĂ

Absolvent,

Dolganiuc Ana

Coordonator științific,

Stanciu Andrei

București 2022



ACADEMIA DE STUDII ECONOMICE DIN BUCUREȘTI
FACULTATEA DE CONTABILITATE ȘI INFORMATICĂ DE
GESTIUNE

ANALIZA COȘULUI DE CUMPĂRĂTURI (SHOPPING BASKET) UTILIZÂND INSTRUMENTE DE ASISTARE A DECIZIEI

Absolvent,

Dolganiuc Ana

Coordonator științific,

Stanciu Andrei

București 2022

Cuprins

Introducere.....	4-8
1. Metode și instrumente de analiză a datelor.....	9-27
1.1 Metodologia științei datelor.....	9-11
1.2 Instrumente de asistare a deciziei.....	11-12
1.3 Inteligența Artificială- domenii de utilizare și tipuri de algoritmi.....	12-18
1.4 Tehnici de asociere.....	18-26
1.5 Studii privind analiza coșului de cumpărături.....	26-27
2. Studiu de caz: Analiza coșului de cumpărături.....	28-42
2.1 Metodologia cercetării.....	28
2.2 Prezentarea bazei de date.....	28-29
2.3 Filtrarea bazei de date.....	29-33
2.4 Analiza și vizualizarea datelor.....	33-38
2.5 Aplicarea algoritmului de asociere Apriori.....	38-42
2.6 Concluzii privind studiul de caz.....	42
Concluzie.....	43-44
Bibliografie.....	45-46
Anexe.....	47-48

Introducere

În era informației și analizei avansate, rapiditatea și adaptabilitatea la schimbare sunt elementele esențiale de supraviețuire. Avansarea colosală a tehnologiei a schimbat profund relațiile interumane, sistemul educațional și desigur, mediul de afaceri. Acum, toate companiile operează în mediul online unde: au acces la un număr nelimitat de clienți, oportunitatea de a colabora cu alte companii internaționale, posibilitatea de promovare a afacerii către clienții potriviți și flexibilitatea de muncă pentru angajați. Revoluționarea domeniului financiar cu ajutorul internetului a fost posibilă datorită a două componente majore: Big Data și AI.

O dată cu apariția internetului au apărut și datele, fără de care mediul online nu ar fi putut exista. În momentul de față peste 3,96 miliarde de oameni sunt utilizatori de social media, cu un procent de creștere de 38,5% pe parcursul a șase ani.¹ Toți acești utilizatori distribuie poze, videoclipuri, mesaje și o cantitate enormă de informație care este stocată de-a lungul unei multitudini de servere prezente în fiecare colț al lumii. Cercetătorii universității din California au estimat că un utilizator mediu produce aproximativ 34 gigabytes pe zi, iar până în 2025 s-au prezis peste 200 zettabytes de informații existente.²

Toate aceste numere au fost introduse sub termenul de Big Data. Big Data se referă la o cantitate masivă de informații produsă din diferite surse: platforme de social media, jurnale web, dispozitive din mediul IoT, senzori și multe altele. Deși datele se consideră “petrolul secolului 21”, analiza lor este motorul cu combustie. Datele brute pot conține informații incerte sau inexacte care trebuie să fie pre-procesate înainte de a fi utilizate la analiză. Prin accesul la această cantitate enormă de informație tot mai multe companii și-au regândit strategiile de vânzare, de marketing și de trecere la alt nivel pe piața competitivă. Acest izvor de date a permis companiilor:

¹ Statista. 2022. [online] Available at: <https://www.statista.com/statistics/278414/number-of-worldwide-social-network-users/>

² Statista. 2022. [online] Available at: <https://www.statista.com/statistics/871513/worldwide-data-created/>

- Să creeze un conținut format din prisma consumatorului – prin intermediul amprentelor digitale, sistemele de inteligență elaborează un profil al consumatorului pe baza căruia îi oferă recomandări personalizate. În acest mod, companiile își pot găsi și segmenta clientela.
- Să crească profitul – cu ajutorul datelor se poate analiza piața într-un nivel de detaliu foarte avansat. Acest privilegiu oferă companiei oportunitatea de a înțelege atât care sunt avantajele competitorilor, cât și punctele slabe și punctele forte ale strategiei proprii de marketing.
- Să ia decizii obiective – big data oferă companiilor șansa de a lua decizii pe baza calculelor matematice și statistice și conform datelor reale. Prin urmare, firmele nu trebuie să facă presupuneri și pot să se bazeze pe fapte logice și imparțiale.³

Analiza coșului de cumpărături cunoscută și sub denumirea de Market Basket Analysis este una dintre cele mai utilizate strategii de inteligență artificială la momentul actual. Această analiză presupune un algoritm ce aparține domeniului de data mining care este folosit pentru a identifica relațiile dintre produse și combinațiile de articole achiziționate simultan. Metoda studiază istoricul tuturor tranzacțiilor făcute de cumpărători și identifică cele mai frecvente produse cumpărate împreună. Tehnica “Market Basket Analysis” este utilizată în deosebi în cadrul promovării produselor la promoții, în cross-selling, marketing și în luarea deciziilor privind producția celor mai profitabile produse.

În momentul de față toate cele mai populare companii din lume folosesc analiza coșului de cumpărături în scopuri de promovare a serviciilor oferite și segmentare a clientelei de bază. Amazon este compania cunoscută pentru fraza “persoanele care au cumpărat acest produs, au achiziționat și următoarele produse”. Astfel, Amazon a implimentat analiza coșului de cumpărături și sistemele de recomandare care studiază comportamentul utilizatorilor și le recomandă combinația de produse frecvent cumpărate de clienți cu un istoric de cumpărare asemănător. Mai mult de atât s-a stabilit faptul că 35% din veniturile totale ale companiei sunt impactate direct de aceste sisteme de recomandare. Alte companii care se folosesc de această tehnică sunt Netflix, Spotify, Starbucks, Meta, Tesla etc.⁴

³ Hartmann, P. M., Zaki, M., Feldmann, N., & Neely, A. (2014). Big data for big business? A taxonomy of data-driven business models used by start-up firms. *Cambridge service alliance*, 1-29

⁴ Linden G, Smith B, York J. Amazon.com recommendation: item-to-item collaborative filtering. *IEEE Internet Comput* 2003;7(1):76–80

În cadrul lucrării de licență mi-am propus analiza în detaliu a comportamentului consumatorului prin intermediul instrumentelor de decizie și înțelegerea relațiilor dintre diverse produse. Motivul pentru care am ales această temă derivă din interesul meu pentru analiza psihologiei clienților, identificarea metodelor ascunse de maximizare a profitului în cadrul unei companii și devansarea concurenților de pe piață cu ajutorul instrumentelor de decizie. Mai mult de atât, analiza coșului de cumpărături este o modalitate bună de a atrage și segmenta clienții potriviți prin promoțiile și strategiile de marketing adecvate. Așadar, obiectivele principale propuse în cadrul acestei lucrări sunt următoarele:

- ✓ Descoperirea și identificarea combinațiilor ascunse de produse cumpărate frecvent împreună
- ✓ Analiza comportamentului cumpărătorilor
- ✓ Creșterea productivității prin identificarea celor mai importante produse ce afectează profitul companiei
- ✓ Stabilirea produselor potrivite pentru a fi puse la promoție
- ✓ Determinarea modului de amplasare a aricolelor în magazin.

În lumina celor discutate, lucrarea conține trei aspecte importante:

1. Prezentarea și expunerea instrumentelor de decizie

Pe parcursul primului subpunct m-am ocupat de prezentarea detaliată a instrumentelor de decizie, care reprezintă programe computerizate ce contribuie la stabilirea deciziilor, judecăților și strategiilor în organizație. Sistemele suport de decizie orientate pe reprezentare din domeniul inteligenței artificiale au fost focusul principal al acestui proiect. Acestea sunt instrumentele esențiale prin intermediul cărora managementul reușește să conducă analize de tip “what if” și să stabilească deciziile optime la nivel de companie. În momentul de față, cele mai utilizate instrumente de decizie din domeniul inteligenței artificiale sunt: Regresia, Copacii de decizie, Clasificarea, Gruparea, Analiza asociativă și Sistemele de recomandare.

2. Prezentarea și descrierea modului de funcționare a tehnicii de asociere Apriori

Instrumentul de decizie prin care se conduce analiza coșului de cumpărături este analiza asociativă. Tehnicile de asociere reprezintă o nișă a învățării automate nesupervizate, cu ajutorul cărora se pot descoperi tipare și conexiuni interesante pe baza seturilor mari de baze de date. Cea mai cunoscută tehnică de învățare prin asociere este metoda Apriori. Algoritmul are capacitatea

de a stoca frecvența k-seturilor de produse anterioare și de a le aplica mai târziu la formarea noilor seturi $k+1$ pe baza acestora. Algoritmul este utilizat în analiza coșului de cumpărături pentru a învăța care produse sunt cumpărate simultan, și care nu au o relevanță mare asupra veniturilor companiei. Coeficienții esențiali în stabilirea regulilor de asociere în cadrul algoritmului sunt:

- Coeficientul de suport(Sup) care sugerează analistului frecvența produsului sau setului de produse apărute în baza de date.
- Coeficientul de încredere(Conf) care reprezintă procentul total al tranzacțiilor care conțin ambele produse A și B, în raport cu toate tranzacțiile ce cuprind doar produsul A.
- Coeficientul de importanță(Lift) care ia în considerație atât ambele frecvențe ale produselor ce apar în tranzacții în mod individual, cât și frecvența acestora regăsite împreună.

Astfel, algoritmul Apriori este util în analiza coșului de cumpărături pentru a învăța care produse sunt cumpărate frecvent împreună, pentru a aplica strategii avansate de cross-selling, marketing și promoții țintite pe captarea atenției clienților.

3. Studiul de caz

În cadrul studiului de caz am utilizat programul informatic Jupyter Notebook care funcționează pe baza limbajului de programare python și am parcurs 5 etape de bază:

- Colectarea datelor – căutarea unei baze de date valide de tip open source a unui magazin de cumpărături online
- Prelucrarea și filtrarea bazei de date – analizarea tipul variabilelor, gruparea datelor și identificarea datelor lipsă sau care nu au sens în baza de date. De asemenea în cadrul
- acestei etape am transformat coloanele în formatul necesar pentru a facilita analiza ulterioară a bazei de date.
- Analiza datelor- pe parcursul acestui pas am analizat comportamentul consumatorilor și am sesizat diferite tipare interesante în ceea ce ține de cele mai profitabile produse și perioade ale magazinului.
- Aplicarea algoritmului de asociere- în urma aplicării algoritmului Apriori am surprins câteva reguli de asociere care ar putea fi aplicate de către management pentru a influența în subconștient decizia cumpărătorilor.

În urma studiului de caz am identificat câteva aspecte interesante privind modul de funcționare al companiei:

1. Cea mai aglomerată perioadă în supermarket este Sâmbăta între orele 12-15, iar cea mai puțin vizitată zi este Miercuri.²³
2. Cel mai popular departament este cel de fructe și legume, urmat de cel de lactate și gustări. Cel mai puțin avantajos departament este cel de crupe.
3. Cel mai cumpărat produs sunt bananele, care apar în peste 16% din tranzacțiile magazinului, urmate de căpșuni, baby spanac și lactate.²⁵
4. Dimineața cumpărătorii tind să cumpere produse de panificație, fructe și produse de lactate(în special lapte și iaurt). Contrar, seara este o cerere mai mare pentru produse și gustări congelate(carne,pizza, înghețată).²⁴
5. Produsele care se cumpără frecvent împreună sunt spanacul și avocado, căpșunile și avocado, lămâile și bananele, avocado și bananele ,și căpșunele și bananele. Astfel managerii ar trebui să amplaseze și să promoveze aceste produse împreună.²⁷

În concluzie, această lucrare este destinată managerilor magazinelor în vederea creșterii profitului prin campaniile potrivite de marketing, maximizării profitului prin focusarea pe produselor populare și gestionării resurselor umane conform perioadelor aglomerate în magazin.

Capitolul 1

Metode și instrumente de analiză a datelor

1.1 Metodologia științei datelor

În momentul de față știința datelor, numită și Data Science, este cel mai popular domeniu din sfera tehnologiei informației și include: știința calculatoarelor, informatica, modelarea statistică și analiza datelor. (Winston, 1984) a descris știința datelor ca fiind utilizarea eficientă a metodelor automatizate cu scopul de a filtra cantități enorme de informații și de a descoperi indici utili pe baza acestora.⁵

Teoretic, știința datelor poate fi definită drept un set de principii care se bazează pe aplicarea analizei asupra datelor extrase.

Scopul deciziei formată în baza tehnicilor de decizie asistată (Data Driven Decision Making) este pentru a stabili cele mai eficiente metode de segmentare a consumatorilor și pentru a descoperi modelele ascunse din spatele datelor structurate și nestructurate. De asemenea decizia reprezintă un conglomerat de tehnici format în baza calculelor matematice, analizei și indicatorilor statistici și nu prin presupuneri. Un model ar fi deciziile luate în domeniul marketingului se efectuează atât pe baza cunoștințelor anagajaților, cât și pe baza comportamentului publicului la reclame asemănătoare.

Procesul de Data Science este compus din următoarele elemente:⁶




Figura 1.1 Metodologia științei datelor

⁵ Winston, P. H. (1984). *Artificial intelligence*. Addison-Wesley Longman Publishing Co., Inc..

⁶ Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of management information systems*, 24(3), 45-77.

1. Identificarea problemei

Înainte de rezolvarea problemei trebuie să înțelegem cu exactitate ce reprezintă aceasta. Datele trebuie transformate în întrebări concrete:

- Cine sunt clienții nostri?
- Cum îi identificăm?
- Care este strategia de business a companiei?
- De ce sunt interesați în produsele noastre și ce produse se vând cel mai bine?

Scopul acestei etape este de a înțelege care este scopul nostru.

2. Colectarea și procesarea datelor

După identificarea problemei și stabilirea unei soluții, începe procesul de colectare a datelor care implică determinarea potențialelor date ce ne-ar putea ajuta la rezolvarea problemei. Această etapă presupune scanarea bazelor de date interne sau cumpărarea unor baze de date externe. Statistica descriptivă și diverse grafice pot fi utilizate pentru a avea o primă perspectivă despre date.

Scopul etapei este de a acumula cât mai multă informație care ne-ar putea fi de ajutor în continuare.

3. Înțelegerea datelor

Etapa de procesare a informației presupune o bună înțelegere a bazei de date și o analiză profundă a acesteia. Pe parcursul etapei trebuie să găsim tiparele ascunse din spatele bazei de date cu ajutorul calculelor statistice și analizei financiare. Se pot utiliza următoarele metode: Statistica univariată, statistica multivariată (dacă variabilele sunt strâns corelate între ele) și histogramele (pentru a vedea cum sunt distribuite valorile și variabilele)

Această etapă este esențială pentru că presupune implementarea gândirii analitice, partea pe care inteligența artificială nu o poate efectua încă.

4. Prelucrarea datelor

După înțelegerea informațiilor trebuie să ne asigurăm că datele pe care le avem sunt relevante.

Pentru aceasta trebuie să ne convingem că:

- Înlocuim valorile care lipsesc
- Ștergem valorile duplicate
- Formatăm informația
- Datele noastre au sens, și cele care nu au sens sunt înlocuite sau șterse

Țelul etapei este de a crea o bază de date cât mai exactă și precisă cu scopul de a ajunge la rezultate corecte și de o acuratețe ridicată.

5. Implimentarea modelului

Procesul de creare și aplicare a modelului este ceea ce diferențiază analiza financiară de știința datelor. Pe parcursul acestei etape este fundamental să alegem sau să creăm modelul care corespunde necesităților noastre. Așadar, trebuie să parcurgem două etape:

- Crearea modelului- Presupune alegerea modelului convenit de inteligență artificială în dependență de situație:
 - Modelele predictive - utilizate în obținerea rezultatelor pentru rezolvarea problemei
 - Modelele descriptive - utilizate pentru evaluarea relațiilor între variabile cu ajutorul rezultatelor cunoscute
- Evaluarea modelului- Presupune analiza rezultatelor după nivelul lor de semnificație statistică, și rafinarea acestuia în dependență de situație

6. Comunicarea rezultatelor

În momentul în care modelul a fost evaluat și implementat se prezintă rezultatele către clienți. În cazul în care problema nu este rezolvată definitiv se trece încă o dată prin tot procesul discutat.

1.2 Instrumente de asistare a deciziei

Decizia poate fi definită în mai multe moduri: soluția adoptată în urma examinării unei probleme⁷; “alegerea unei strategii de acțiune”⁸(Fishburn, 1964); “o alegere ce conduce spre obiectivul dorit”⁹ (Churchman, 1968). În principiu decizia prezintă alegerea celei mai oportune soluții pentru orice tip de situație (fie ad-hoc, fie planficată) la momentul potrivit. Știința datelor a schimbat în totalitate procesul de luare a deciziilor datorită noilor instrumente de asistare a deciziei oferite de inteligența artificială.

Sistemele suport de decizie(SSD) reprezintă programe computerizate ce contribuie la stabilirea deciziilor, judecăților și strategiilor în organizație. Un SSD analizează o cantitate enormă de date și o

⁷ <https://dexonline.ro/definitie/decizie>

⁸ Fishburn, P. C. (1989). Foundations of decision analysis: along the way. *Management science*, 35(4), 387-405.

⁹ Kourteli, L. (2000). Scanning the business environment: some conceptual issues. *Benchmarking: An international journal*.

întocmește în așa mod, ca aceasta utilizată eficient la rezolvarea problemelor și în luarea deciziilor. Caracteristicile SSD-urilor sunt de a ușura efortul persoanei ce se ocupă de luarea deciziei și de amplificarea capacității acestuia. De asemenea, acestea sunt utilizate în abordarea problemelor semistructurate, unde pe lângă deciziile computerizate, specialistul își formează o decizie prin judecata proprie.

Conform clasificării tradiționale există 5 tipuri de sisteme suport de decizie:¹⁰

1. SSD orientate pe date – utilizate la manipularea și gestiunea datelor cu ajutorul instrumentelor
2. SSD orientate pe modele- utilizate la analizarea și gestiunea bazelor de date simple
3. SSD orientate pe optimizare - oferă soluții ce includ funcții matematice
4. SSD orientate pe sugestii – folosite în momentul în care deciziile sunt luate pe baza unor decizii bine-structurate
5. SSD orientate pe reprezentare – au capacitatea să conducă analize de tip what if și să calculeze rezultatele diferitor căi de decizie, bazate pe diferite simulări

În cadrul lucrării de licență mă voi concentra pe sistemele suport de decizie ce țin de domeniul Inteligenței artificiale și anume SSD orientate pe reprezentare.

1.3 Inteligența Artificială- domenii de utilizare și tipuri de algoritmi

În ultima decadă termenul de inteligență artificială a devenit din ce în ce mai răspândit, însă ce presupune acesta? AI reprezintă capacitatea unei mașini de a imita funcțiile îndeplinite de creierul uman precum: raționamentul, învățarea, planificarea și creativitatea. AI oferă sistemelor tehnice capacitatea de a înțelege mediul în care acesta funcționează, să lucreze asupra acestei percepții și să rezolve probleme, cu scopul de a atinge obiectivul propus. Calculatorul primește datele, le prelucerează și reacționează.

Există patru tipuri de sisteme cu inteligență artificială:

- Sisteme care gândesc precum oamenii- reprezintă sistemele care îndeplinesc funcții, la care oamenii sunt mai buni decât calculatoarele în momentul de față și posedă următoarele aptitudini:
 - Înțelegerea limbajului uman
 - Stocarea noilor informații
 - Învățarea automata

¹⁰ Power, D. J. (2002). *Decision support systems: concepts and resources for managers*. Greenwood Publishing Group.

- Perceperea vizuală
- Controlarea obiectelor
- Sisteme care acționează precum oamenii - presupune capacitatea de învățare și luare a deciziilor în mod autonom
- Sisteme care gândesc rațional- sugerează utilizarea logicii prin abilitatea de a percepe mediul înconjurător și a acționa conform situației
- Sisteme care acționează rațional- reprezintă adaptarea la diverse situații și acționarea în mod independent¹¹

Tipuri de Inteligență Artificială

Un sistem de Inteligență artificială are capacitatea de a se dezvolta prin următoarele trei tipuri de învățare:

1. Învățarea mecanică (Machine Learning)
2. Învățarea profundă (Deep learning)
3. Rețele neurale (Neural Networks)

1) Învățarea mecanică (Machine Learning)

Învățarea mecanică este momentan cea mai folosită metodă de învățare a sistemului AI. Aceasta presupune primirea unei cantități enorme de informație, pe baza căreia acționează, fără integrarea unui cod specific. Inteligența artificială se referă la creare mașinilor inteligente cu capacitatea de a imita modul de gândire umană, pe când învățarea automată reprezintă un subset al inteligenței artificiale care permite mașinilor să învețe din date, fără necesitatea de a fi programate în mod explicit. Astfel, putem deduce faptul că învățarea mecanică este un subdomeniu al inteligenței artificiale, prin care mașinile reușesc să asimileze informația pe baza unui istoric. Pionerul învățării automate, Tom M. Mitchell a descris învățarea automată ca “studiul algoritmilor de calcul care permit programelor computerizate să se îmbunătățească automat prin experiența acumulată”¹².

¹¹ Jordan, M. I., & Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245), 255-260.

¹² Michalski, R. S., Carbonell, J. G., & Mitchell, T. M. (Eds.). (2013). *Machine learning: An artificial intelligence approach*. Springer Science & Business Media.

Acest tip de învățare se împarte în două categorii: Învățare mecanică asistată (Supervised Machine Learning) și Învățare mecanică neasistată (Unsupervised Machine Learning).

Învățare mecanică asistată	Învățare mecanică neasistată
Definiție	
Sistemul este antrenat prin implimentarea unei baze de date uriașe care conține valori filtrate de programator, cu ajutorul căruia acesta învață să clasifice datele și să prezică tendințele viitoare.	Sistemul este antrenat prin implimentarea unei baze de date uriașe care conține valori nefiltrate, pe baza căruia acesta învață să clasifice și să asocieze datele cu scopul de a identifica anumite șabloane.
Domenii de utilizare	
Clasificarea imaginilor, documentelor și cuvintelor scrise Previziunea tendințelor și rezultatelor viitoare prin învățarea tiparelor din setul propus pentru antrenament	Grupează seturi de date conform caracteristicilor asemănătoare Înțelege în mod independent diferențele dintre variabile în cadrul setului de date
Exemple	
Clasificarea imaginilor Analiza predictivă Segmentarea clienților Diagnostiche medicale Evaluarea riscurilor Clasificarea a secvențelor de ADN	Recunoașterea obiectelor și imaginilor Detectarea anomaliilor Sisteme de recomandare Asocierea categoriilor Detectarea datelor frauduloase Algoritmi de căutare

Tabel 1.1 Învățarea mecanică

2) Rețele neurale (Neural Networks)

Rețelele neurale, după cum sugerează și denumirea, sunt inspirate după creierul uman. Modelul este compus din trei straturi:

- Stratul de intrare (input layer)- unde informația este preluată și transmisă mai departe în stratul ascuns. Numărul de neuroni ce aparțin acestui strat este egal cu numărul caracteristicilor din baza de date.

- b. Stratul ascuns (hidden layer)- recepționează informația transmisă de stratul inițial, o prelucrează cu ajutorul înmulțirii matricelor de neuroni și a aplicării funcțiilor predefinite.
- c. Stratul de ieșire (output layer)- preia informația procesată în stratul ascuns și aplică funcțiile sigmoid sau softmax, cu ajutorul cărora transformă rezultatele în probabilități.¹³

Domenii de utilizare:

- Recunoaștere facială
- Analiza scrisului de mână și verificare semnăturii
- Prezicerea pieței de capital
- În industria aerospațială
- În social media

3) Învățarea profundă (Deep Learning)

Învățarea profundă este o continuare a rețelelor neurale, care se diferențează de acestea prin numărul imens de substraturi din care este compus stratul ascuns.

Domenii de utilizare:

- Asistenți virtuali
- Chabots
- Asistența medicală
- În robotică
- Detectarea știrilor false

Diferențe între AI și ML¹⁴

Inteligența artificială	Învățarea automată
Simulează comportamentul uman	Învață automat din datele istorice fără să programeze explicit
Este utilizat pentru a îndeplini orice sarcină pe care o poate îndeplini și un om	Este utilizat pentru a obține rezultate cât mai exacte
AI lucrează pentru a crea un model inteligent capabil să îndeplinească sarcini complexe	

¹³ C. M. Bishop, Neural Networks for Statistical Pattern Recognition (1994), Oxford University Press, Oxford.

¹⁴ Laurence Moroney. (2020). AI and Machine Learning for Coders. Sebastopol: Gravenstein Highway North.

Este preocupată de maximizarea șanselor de success Utilizare: Siri, Asistența virtuală, jocuri online, robot umanoid inteligent etc.	ML lucrează pentru a îndeplini sarcini exacte conform unei instrucțiuni Este preocupată de acuratețe și rezultate exacte Utilizare: Sisteme de recomandare, algoritmi de căutare, detectarea anomaliilor , recunoaștere facial etc.
--	--

Tabel 1.2 Analiză comparativă între învățarea mecanică și inteligența artificială¹⁴

Tipuri de algoritmi în inteligența artificială




Figura 1.2 Tipuri de algoritmi în inteligența artificială

Instrumente necesare pentru utilizarea Inteligenței Artificiale

Platforme de dezvoltare: Jupyter Notebook, RStudio, PyCharm, Visual Studio Code

Aplicații integrate:




Figura 1.3 Instrumente utilizate în Inteligența Artificială

Librării open source:




Figura 1.4 Librării utilizate în inteligența artificială

1.4 Tehnici de asociere

Tehnicile de asociere reprezintă o nișă a învățării automate nesupervizate, cu ajutorul cărora se pot descoperi tipare și conexiuni interesante pe baza seturilor mari de baze de date. Acestea se calculează prin estimarea probabilității unei relații dintre variabilele bazei de date și funcționează conform declarației “Dacă→Atunci”. Spre exemplu, dacă cineva vrea să cumpere un telefon, atunci este foarte probabil ca acesta să cumpere și o husă împreună cu el. Scopul regulilor de asociere este de a reduce costurile și a crește veniturile prin descoperirea și aplicarea unor conexiuni între produsele preferate de clienți.

Tehnicile de asociere au un impact deosebit într-o multitudine de zone cum ar fi:

Medicină- Doctorii folosesc sistemele de asociere pentru a găsi posibile legături între bolile pacienților care au suferit de aceleași simptome

Vânzări- Sistemele pot identifica care sunt cele mai comune produse cumpărate împreună și își ajustează strategiile de marketing conform acestor informații.

Divertisment- Tehnicile de asociere sunt integrate în sistemele de recomandare, cum ar fi Netflix, Youtube, Instagram, Tik Tok, cu ajutorul cărora se creează un profil al utilizatorului care urmărește activitățile acestuia și îi oferă produse similare pe placul lui.

Web design- Programatorii pot analiza frecvența de accesare a unei setări sau funcții și își ajustează designul conform preferinței consumatorului.¹⁵

În domeniul inteligenței artificiale, tehnicile de asociere pot fi aplicate în analiza comportamentului consumatorului în spațiul web (Web mining) și în analiza coșului de cumpărături. În domeniul Web mining, regulile de asociere sunt formate pe baza activității utilizatorilor pe internet prin accesarea site-urilor, abonarea la diferite pagini web și în baza istoricului de căutare cu ajutorul supravegherii loginuri-lor de pe serverul web. În analiza coșului de cumpărături se identifică care sunt cele mai comune produse cumpărate împreună și se analizează în detaliu fiecare produs în dependență de comportamentul consumatorului în relație cu acesta. Analiza coșului de cumpărături este utilizată la eficientizarea producției, reducerea costurilor și creșterea profitului conform psihologiei clienților.

Învățarea automată nesupervizată prezintă trei algoritmi de învățare prin asociere:

¹⁵ Agrawal R, Imieliński T, Swami A. Mining association rules between sets of items in large databases. In: ACM SIGMOD Record. ACM. 1993;22: 207–216

- Algoritmul Apriori- cunoscut ca și cel mai important algoritm de asociere se aplică la bazele de date mari ce conțin tranzacții. Este utilizat în analiza coșului de cumpărături pentru a învăța care produse sunt cumpărate simultan, și care nu au o relevanță mare asupra veniturilor companiei.
- Algoritmul de creștere al tiparelor frecvente- este o variantă mai avansată a algoritmului Apriori, fiind compus dintr-un copac de decizie format pe baza conexiunilor frecvente dintre variabile.
- Algoritmul Eclat- este un algoritm mai simplist al modelului Apriori, însă este mai ușor de folosit și mai eficient din punct de vedere al timpului de execuție.¹⁶

Modelul de funcționare a tehnicilor de asociere

Pentru utilizarea învățării prin asociere este nevoie de o bază de date care cuprinde tranzacțiile magazinului analizat. Prin intermediul acestora sunt întocmite regulile de asociere cu ajutorul cărora se prezice frecvența apariției al unui produs, calculate pe baza relației dintre acesta și alte produse componente ale tranzacției.

Etape utilizate în stabilirea regulilor de asociere:

- Coeficientul de suport (Sup)

Coeficientul de suport reprezintă numărul de tranzacții care conțin produsele apărute împreună în raport cu procentul numărului total de tranzacții. Acesta, în esență, sugerează utilizatorului frecvența produsului sau setului de produse apărute în baza de date.

$$\text{Suport } (A \rightarrow B) = P(A \cap B) = \frac{(\text{Număr de tranzacții ce conțin } A \text{ și } B)}{(\text{Total număr tranzacții})}$$

Astfel, acesta este interpretat ca raportul tranzacțiilor ce conțin atât produsul A cât și produsul B.

- Coeficient de încredere (Conf)

Coeficientul de încredere reprezintă procentul total al tranzacțiilor care conțin ambele produse A și B, în raport cu toate tranzacțiile ce cuprind produsul A. Cu alte cuvinte, acest coeficient reprezintă

¹⁶ Zhang C. Association rule mining: models and algorithms / C. Zhang, S. Zhang. – Berlin: Springer-Verlag. – 2002. – 238 p.

probabilitatea condițională ca toate tranzacțiile ce conțin produsele A și B să se conțină în numărul total de tranzacții ce aparțin produsului A.

$$\text{Conf}(A \rightarrow B) = P(B|A) = \frac{\text{sup}(A \cap B)}{\text{sup}(A)} = \frac{(\text{Număr de tranzacții ce conțin A și B})}{(\text{Total număr tranzacții ce conțin A})}$$

Astfel, coeficientul este interpretat ca și raportul dintre numărul de tranzacții care conțin simultan produsele A și B, și numărul de tranzacții ce conțin doar produsul A.

- Coeficient de importanță (Lift)

Coeficient de importanță reprezintă raportul dintre frecvența apariției produselor A și B împreună în comparație cu numărul total de tranzacții ce conțin doar produsul A, și numărul total de tranzacții ce conțin doar produsul B. Așadar, acesta este calculat ca și fracție între coeficientul de încredere și total număr tranzacții ce conțin produsul B.

$$\text{Lift}(A \rightarrow B) = \frac{\text{sup}(A \cap B)}{\text{sup}(A) * \text{sup}(B)} = \frac{\text{conf}(A \rightarrow B)}{\text{sup}(B)} = \frac{(\text{Număr de tranzacții ce conțin A și B})}{(\text{Total număr tranzacții ce conțin B})}$$

Atunci când valoarea lui coeficientului este aproape de 1, înseamnă că produsele apar împreună conform estimărilor făcute, atunci când valoarea este mai mare decât 1 înseamnă că produsele apar împreună mai mult decât s-a estimat, iar în cazul în care coeficientul este mai mic decât 1, rezultă că produsele apar mai rar împreună.

Acest coeficient este important pentru că ia în considerație atât ambele frecvențe ale produselor ce apar în tranzacții în mod individual, cât și frecvența acestora regăsite împreună.

- Coeficient de convingere (Conv)

Coeficient de convingere calculează frecvența produsului A în baza de date fără a lua în considerație produsul B. În esență este o metodă pentru a ne asigura că regulile pe care le-am întocmit nu fac predicții greșite.

$$\text{Conv}(A \rightarrow B) = \frac{1 - \text{sup}(B)}{1 - \text{conf}(A \rightarrow B)} = \frac{(1 - \text{Total număr tranzacții ce conțin B})}{(1 - \text{Număr de tranzacții ce conțin A și B})}$$

Tehnicile de asociere sunt utilizate în mod deosebit la analiza bazelor mari de date. Datele pot fi colectate prin intermediul codurilor de bare. Bazele de date trebuie să conțină tranzacțiile unice făcute de clienți, asupra cărora se aplică tehnicile de învățare prin asociere ulterior. În momentul creării noilor reguli de asociere, managerul poate grupa produsele în cel mai convenabil mod posibil.

De asemenea, regulile de asociere pot fi utilizate în cross-selling, marketing și promoții țintite pe captarea atenției clienților.¹⁷

Algoritmul Apriori

Algoritmul Apriori- cunoscut ca și cel mai important algoritm de asociere care se aplică la bazele de date mari ce conțin tranzacții. Numele de “Apriori” derivă de la capacitatea algoritmului de a stoca frecvența k-seturilor de produse anterioare și a le aplica mai târziu la formarea noilor seturi k+1 pe baza acestora. Algoritmul este utilizat în analiza coșului de cumpărături pentru a învăța care produse sunt cumpărate simultan, și care nu au o relevanță mare asupra veniturilor companiei.

Exemplu de aplicare a algoritmului :

Număr tranzacție	Produse componente
1.	Roșii, Castraveți, Morcovi
2.	Roșii, Varză
3.	Varză, Porumb
4.	Roșii, Castraveți, Varză
5.	Roșii, Castraveți, Dovlecei, Morcovi, Varză
6.	Castraveți, Dovlecei, Morcovi
7.	Castraveți, Morcovi, Dovlecei

Tabel 1.5 Aplicarea algoritmului Apriori (etapa nr. 1)

Set de date= {Roșii, Castraveți, Morcovi, Varză, Porumb, Dovlecei}, iar număr tranzacții=7

1) Stabilirea unui coeficient optim de suport

Suport minim= 2

2)Efectuarea iterațiilor de calculare a coeficientului de suport

Coeficientul de suport de gradul 1:

Produs	Suport
Roșii	4
Castraveți	5

¹⁷ Ke Y. An information-theoretic approach to quantitative association rule mining / Y. Ke, J. Cheng, N. Wilfred // Knowledge and Information Systems. – 2008. – Vol. 16. – № 2. – P. 213-244.

Morcovi	4
Varză	4
Porumb	1
Dovlecei	3

Tabel 1.6 Aplicarea algoritmului Apriori (etapa nr. 2)

După prima iterație rezultă că putem elimina produsul porumb, al cărui coeficient de suport=1 și este mai mic decât suport minim 2.

$$\text{Sup(Porumb)}=1 < \text{Sup min}(2)$$

Coeficientul de suport de gradul 2 :

Set de produse	Suport
Roșii, Castraveți	$\text{Sup(Roșii, Castraveți)} = 3$
Roșii, Morcovi	$\text{Sup(Roșii, Morcovi)} = 2$
Roșii, Varză	$\text{Sup(Roșii, Varză)} = 3$
Roșii, Dovlecei	$\text{Sup(Roșii, Dovlecei)} = 1$
Castraveți, Morcovi	$\text{Sup(Castraveți, Morcovi)} = 4$
Castraveți, Varză	$\text{Sup(Castraveți, Varză)} = 2$
Castraveți, Dovlecei	$\text{Sup(Castraveți, Dovlecei)} = 3$
Varză, Morcovi	$\text{Sup(Varză, Morcovi)} = 1$
Varză, Dovlecei	$\text{Sup(Varză, Dovlecei)} = 1$
Morcovi, Dovlecei	$\text{Sup(Morcovi, Dovlecei)} = 3$

Tabel 1.7 Aplicarea algoritmului Apriori (etapa nr. 3)

După a doua iterație rezultă că putem elimina seturile de produse: “Roșii, Dovlecei”, “Varză, Morcovi”, “Varză, Dovlecei” .

$$\text{Sup(Roșii, Dovlecei)}=1 < \text{Sup min}(2)$$

$$\text{Sup(Varză, Morcovi)} = 1 < \text{Sup min}(2)$$

$$\text{Sup(Varză, Dovlecei)} = 1 < \text{Sup min}(2)$$

Coeficientul de suport de gradul 3 :

Set de produse	Suport
----------------	--------

Roșii, Castraveți, Morcovi	Sup(Roșii,Castraveți, Morcovi) = 2
Roșii, Castraveți, Varză	Sup(Roșii,Castraveți, Varză) = 2
Castraveți,Dovlecei, Morcovi	Sup(Castraveți, Dovlecei, Morcovi) = 2

Tabel 1.8 Aplicarea algoritmului Apriori (etapa nr. 4)

După a treia iterație rezultă că seturile “Roșii, Castraveți, Morcovi” , “Roșii, Castraveți, Varză” , “Castraveți,Dovlecei, Morcovi” rămân, însă algoritmul se oprește aici pentru că nu vor mai fi seturi de produse frecvente în continuare.

3) Coeficient de încredere (Conf)

Astfel, după ce am analizat și găsit cele mai frecvente seturi de produse din baza de date, trebuie să stabilim regulile de asociere pentru fiecare set.

$$\text{Conf}(A \rightarrow B) = P(B|A) = \frac{\text{sup}(A \cap B)}{\text{sup}(A)} = \frac{(\text{Număr de tranzacții ce conțin } A \text{ și } B)}{(\text{Total număr tranzacții ce conțin } A)}$$

Coeficient minim de încredere= 60%

- Setul 1 (Roșii, Castraveți, Morcovi)

$$\text{Conf}(\text{Roșii,Castraveți} \rightarrow \text{Morcovi}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Morcovi})}{\text{Sup}(\text{Roșii,Castraveți})} = \frac{2}{3} = 67\%$$

$$\text{Conf}(\text{Roșii,Morcovi} \rightarrow \text{Castraveți}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Morcovi})}{\text{Sup}(\text{Roșii,Morcovi})} = \frac{2}{2} = 100\%$$

$$\text{Conf}(\text{Morcovi,Castraveți} \rightarrow \text{Roșii}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Morcovi})}{\text{Sup}(\text{Morcovi,Castraveți})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Roșii} \rightarrow \text{Morcovi, Castraveți}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Morcovi})}{\text{Sup}(\text{Roșii})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Morcovi} \rightarrow \text{Roșii, Castraveți}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Morcovi})}{\text{Sup}(\text{Morcovi})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Castraveți} \rightarrow \text{Roșii, Morcovi}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Morcovi})}{\text{Sup}(\text{Castraveți})} = \frac{2}{5} = 40\%$$

- Setul 2 (Roșii, Castraveți, Varză)

$$\text{Conf}(\text{Roșii,Castraveți} \rightarrow \text{Varză}) = \frac{\text{Sup}(\text{Roșii,Castraveți,Varză})}{\text{Sup}(\text{Roșii,Castraveți})} = \frac{2}{3} = 67\%$$

$$\text{Conf}(\text{Roşii, Varză} \rightarrow \text{Castraveţi}) = \frac{\text{Sup}(\text{Roşii, Castraveţi, Varză})}{\text{Sup}(\text{Roşii, Varză})} = \frac{2}{3} = 67\%$$

$$\text{Conf}(\text{Varză, Castraveţi} \rightarrow \text{Roşii}) = \frac{\text{Sup}(\text{Roşii, Castraveţi, Varză})}{\text{Sup}(\text{Varză, Castraveţi})} = \frac{2}{2} = 100\%$$

$$\text{Conf}(\text{Roşii} \rightarrow \text{Varză, Castraveţi}) = \frac{\text{Sup}(\text{Roşii, Castraveţi, Varză})}{\text{Sup}(\text{Roşii})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Varză} \rightarrow \text{Roşii, Castraveţi}) = \frac{\text{Sup}(\text{Roşii, Castraveţi, Varză})}{\text{Sup}(\text{Varză})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Castraveţi} \rightarrow \text{Roşii, Varză}) = \frac{\text{Sup}(\text{Roşii, Castraveţi, Varză})}{\text{Sup}(\text{Castraveţi})} = \frac{2}{5} = 40\%$$

- Setul 3 (Castraveţi, Dovlecei, Morcovi)

$$\text{Conf}(\text{Dovlecei, Castraveţi} \rightarrow \text{Morcovi}) = \frac{\text{Sup}(\text{Castraveţi, Dovlecei, Morcovi})}{\text{Sup}(\text{Dovlecei, Castraveţi})} = \frac{2}{3} = 67\%$$

$$\text{Conf}(\text{Dovlecei, Morcovi} \rightarrow \text{Castraveţi}) = \frac{\text{Sup}(\text{Castraveţi, Dovlecei, Morcovi})}{\text{Sup}(\text{Dovlecei, Morcovi})} = \frac{2}{3} = 67\%$$

$$\text{Conf}(\text{Morcovi, Castraveţi} \rightarrow \text{Dovlecei}) = \frac{\text{Sup}(\text{Castraveţi, Dovlecei, Morcovi})}{\text{Sup}(\text{Morcovi, Castraveţi})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Dovlecei} \rightarrow \text{Morcovi, Castraveţi}) = \frac{\text{Sup}(\text{Castraveţi, Dovlecei, Morcovi})}{\text{Sup}(\text{Dovlecei})} = \frac{2}{3} = 67\%$$

$$\text{Conf}(\text{Morcovi} \rightarrow \text{Dovlecei, Castraveţi}) = \frac{\text{Sup}(\text{Castraveţi, Dovlecei, Morcovi})}{\text{Sup}(\text{Morcovi})} = \frac{2}{4} = 50\%$$

$$\text{Conf}(\text{Castraveţi} \rightarrow \text{Dovlecei, Morcovi}) = \frac{\text{Sup}(\text{Castraveţi, Dovlecei, Morcovi})}{\text{Sup}(\text{Castraveţi})} = \frac{2}{5} = 40\%$$

În urma identificării coeficientului de încredere putem concluziona faptul că există 7 reguli de asociere care îndeplinesc condiția în care coeficientul de încredere este de minim 60%

1. (Roşii, Castraveţi $\rightarrow$ Morcovi)
2. (Roşii, Morcovi $\rightarrow$ Castraveţi)
3. (Roşii, Castraveţi $\rightarrow$ Varză)
4. (Roşii, Varză $\rightarrow$ Castraveţi)
5. (Varză, Castraveţi $\rightarrow$ Roşii)
6. (Dovlecei, Castraveţi $\rightarrow$ Morcovi)

7. (Dovlecei, Morcovi $\rightarrow$ Castraveți)

4) Coeficientul de importanță (Lift)

$$\text{Lift}(A \rightarrow B) = \frac{\text{sup}(A \cap B)}{\text{sup}(A) * \text{sup}(B)} = \frac{\text{conf}(A \rightarrow B)}{\text{sup}(B)} = \frac{(\text{Număr de tranzacții ce conțin } A \text{ și } B)}{(\text{Total număr tranzacții ce conțin } A)}$$

$$\text{Lift}(\text{Roșii, Castraveți} \rightarrow \text{Morcovi}) = \frac{\text{conf}(\text{Roșii, Castraveți} \rightarrow \text{Morcovi})}{\text{sup}(\text{Morcovi})} = \frac{67\%}{4} = 16\%$$

$$\text{Lift}(\text{Roșii, Morcovi} \rightarrow \text{Castraveți}) = \frac{\text{conf}(\text{Roșii, Morcovi} \rightarrow \text{Castraveți})}{\text{sup}(\text{Castraveți})} = \frac{100\%}{5} = 25\%$$

$$\text{Lift}(\text{Roșii, Castraveți} \rightarrow \text{Varză}) = \frac{\text{conf}(\text{Roșii, Castraveți} \rightarrow \text{Varză})}{\text{sup}(\text{Varză})} = \frac{67\%}{4} = 16\%$$

$$\text{Lift}(\text{Roșii, Varză} \rightarrow \text{Castraveți}) = \frac{\text{conf}(\text{Roșii, Varză} \rightarrow \text{Castraveți})}{\text{sup}(\text{Castraveți})} = \frac{67\%}{5} = 14\%$$

$$\text{Lift}(\text{Varză, Castraveți} \rightarrow \text{Roșii}) = \frac{\text{conf}(\text{Varză, Castraveți} \rightarrow \text{Roșii})}{\text{sup}(\text{Roșii})} = \frac{100\%}{4} = 25\%$$

$$\text{Lift}(\text{Dovlecei, Castraveți} \rightarrow \text{Morcovi}) = \frac{\text{conf}(\text{Dovlecei, Castraveți} \rightarrow \text{Morcovi})}{\text{sup}(\text{Morcovi})} = \frac{67\%}{4} = 16\%$$

$$\text{Lift}(\text{Dovlecei, Morcovi} \rightarrow \text{Castraveți}) = \frac{\text{conf}(\text{Dovlecei, Morcovi} \rightarrow \text{Castraveți})}{\text{sup}(\text{Castraveți})} = \frac{67\%}{5} = 14\%$$

Prin identificarea coeficientului de importanță putem concluziona faptul că regulile de asociere sunt valide și cu un grad de semnificație ridicat.

În concluzie, deși algoritmul Apriori poate fi mai lent din cauza numărului mare de iterații și seturi candidat, este un model esențial ce poate fi utilizat într-o multitudine de domenii cum ar fi: vânzări, marketing, medicină, web development, web mining, divertisment, etc.¹⁸

1.5 Studii privind analiza coșului de cumpărături

Analiza comportamentală (cunoscută și sub denumirea de Behavioral Economics) a fost prezentată de către Richard Thaler în 2008 și publicată mai târziu (2015) în cartea: “Misbehaving: The Making of Behavioral Economics”. Aceasta reprezintă o combinație între psihologie și economie care are drept scop urmărirea și investigarea efectului psihologic, social, emoțional și cultural asupra

¹⁸ Bob Violino. *Machine learning: When to use each method and technique*. InfoWorld. SEP 6, 2018

principiilor economice clasice.¹⁹ Prin aplicarea analizei comportamentale asupra unei firme, managementul își poate ajusta strategiile de business în conformitate cu deciziile consumatorilor. Majoritatea companiilor din domeniul vânzărilor au început să aplice calculele matematice și statistice în analiza psihologiei clienților încă din anul 2016, devenind una din cele mai importante tehnici în crearea profilului consumatorului în prezent.²⁰

Pe parcursul studierii analizei comportamentale a clienților s-au observat foarte multe aspecte interesante și importante în gestionarea businessului cum ar fi impactul atmosferei din magazin asupra motivației consumatorului de a-și face cumpărăturile. Conform studiului realizat de University of Baltimore, factorii externi cum ar fi design-ul, ambianța, păturile sociale și imaginea magazinului sunt considerați drept stimuli ai nivelurilor de dopamină a creierului uman și impactează timpul petrecut în magazin, numărul de produse cumpărate și valoarea coșului de cumpărături.²¹ Alte aspecte semnificative descoperite de analiza comportamentală sunt cele mai preferate ore de către consumatori pentru a-și face achizițiile. S-a demonstrat că timpul este un factor esențial pentru clienți.²² În articolul publicat de Google Maps se specifică faptul că cea mai aglomerată și profitabilă perioadă pentru un magazin este în ziua de Sâmbătă între orele 12 și 15, când oamenii nu sunt la lucru și se ocupă de aprovizionarea frigiderului pentru toată săptămâna.²³ De asemenea, Jonah Berger atestă în articolul său că, perioada zilei afectează apetitul și gama de preferințe a consumatorilor.²⁴ Astfel, dimineața există o tendință mai mare către produse sănătoase precum fructele și legumele, dar și pentru produse de lactate., în timp ce seara s-a observat o preferință mult mai mare pentru produse congelate și gustări. În ceea ce ține de coșul de cumpărături, s-a descoperit faptul că bananele sunt cele mai vândute produse, fiind mai populare decât merele și portocalele cumpărate împreună.²⁵ Un alt aspect ce afectează decizia consumatorului este poziția produselor în supermarket. Conform statisticilor făcute de US Census Bureau în analiza indicatorului “Consumer Price Index”, s-a demonstrat faptul că produsele cumpărate frecvent împreună trebuie amplasate în aceeași vecinătate și pot fi utilizate în sporirea campaniilor de publicitate.²⁶ Astfel, s-a observat un grad de corelație înalt între tranzacțiile ce conțin avocado și alte

¹⁹ Thaler, R. H. (2015). *Misbehaving: The making of behavioral economics*. W W Norton & Co.

²⁰ Tversky, A., & Kahneman, D. (1974). Judgment under Uncertainty: Heuristics and Biases. *Science*, 185(4157), 1124–1131. <http://www.jstor.org/stable/1738360>

²¹ Anderson, P. (1986). *Personality, perceptions and emotion-state factors in approach-avoidance behaviors in the store environment*. In Terence A. Shimp et al. (Eds.), *1986 AMA educators' proceedings* (pp. 35–39). Chicago: American Marketing Association.

²² Google Maps. 2020. [online] Available at: <https://blog.google/products/maps/2020holiday-trends-google-maps/>

²³ Google Maps. 2020. [online] Available at: <https://blog.google/products/maps/2020holiday-trends-google-maps/>

²⁴ *Journal of Consumer Research*, Volume 46, Issue 1, June 2019, Pages 20–35, <https://doi.org/10.1093/jcr/ucy061>

²⁵ Koepfel, D. (2008). *Banana: The fate of the fruit that changed the world*. New York: Hudson Street Press

²⁶ U.S. Bureau of Labour Statistics. 2022. [online] Available at: https://www.bls.gov/cpi/questions-and-answers.htm#Question_6

produse precum spanac, banane și căpșuni datorită nivelului mare combinație a acestor produse împreună(în special la prepararea smoothie-urilor).²⁷ De asemenea, o combinație frecvent întâlnită sunt căpșunile și bananele conform studiilor publicate de Universitatea politehnică din California.²⁸

Studiu de caz: Analiza coșului de cumpărături

2.1 Metodologia cercetării

²⁷ Sheldon Bosio, A. (2015).” Examining consumer preferences within the avocado industry: does point of origin matter?”. Unpublished doctoral dissertation, California Polytechnic State University, California

²⁸ Borrero, Juan D., and Alberto Zabalo. 2021. "Identification and Analysis of Strawberries' Consumer Opinions on Twitter for Marketing Purposes" *Agronomy* 11, no. 4: 809. <https://doi.org/10.3390/agronomy11040809>

În cadrul studiului de caz am utilizat baza de date a unui magazin, pe baza căruia am făcut analiza datelor după indicii oferți și am continuat cu aplicarea algoritmului de inteligență artificială în vederea analizei coșului de cumpărături. În prima etapă m-am ocupat de filtrarea datelor, stabilirea indicilor relevanți studiului de caz și înlocuirea valorilor lipsă. După optimizarea bazei de date am început analiza acestora cu ajutorul graficelor reprezentative, cu ajutorul cărora a fost posibilă vizualizarea în detaliu a datelor și înțelegerea comportamentului consumatorilor. Într-un final am aplicat algoritmul Apriori cu scopul de a vedea care set de produse sunt cumpărate frecvent împreună. Analiza a fost făcută în aplicația Jupyter Notebook care funcționează pe baza limbajului de programare python și încorporează text narativ, ecuații matematice și statistice și grafice. Am ales acest program datorită varietății mari de librării, eficienței de parcurgere a bazelor mari de date și posibilităților infinite de creare a graficelor și diagramelor. De asemenea Jupyter Notebook este cel mai popular instrument folosit de specialiștii din știința datelor, alături de programul R.

2.2 Prezentarea bazei de date

Datele utilizate pentru analiză provin din baza de date a unui magazin alimentar cu denumirea de “Instacart”, publicată în anul 2017.²⁹ Baza de date a fost transformată în una open source cu scopul de a descoperi tiparele din spatele acestora și de a efectua analize utile în vederea îmbunătățirii strategiilor de marketing, eficientizare a producției și sporirii vânzărilor. Baza este una de tip relaționar, are peste 50.000 tranzacții acumulate în timpul perioadei de 6 luni și este compusă din cinci tabele:

- Departament- conține numele fiecărui departament și cheia unică atribuită acestora
- Tip produs- conține cheia primară atribuită fiecărui tip de produs și tipul produsului
- Produse- conține numele fiecărui produs și cheia unică atribuită produsului, cheia externă ce aparține fiecărui departament și cheia externă ce leagă produsul de tipul produsului
- Comenzi- cuprinde cheia primară a fiecărei comenzi, numărul comenzii, numărul unic al cumpărătorului, ziua din săptămână a comenzii și ora comenzii
- Produse_comandate_înainte- conține ordinea în care produsul a fost adăugat la coș, indicatorul dacă produsul a fost comandat din nou, cheia externă ce face legătură cu tabelul „produs” și cheia externă ce leagă tabelul de tabelul comenzi.

²⁹ “The Instacart Online Grocery Shopping Dataset 2017”, Accessed from <https://www.instacart.com/datasets/grocery-shopping-2017> on 30.05.2022




Figura 2.1 Structura bazei de date

2.3 Filtrarea bazei de date

Pregătirea bazei de date

1) Încărcarea fișierelor în program:

a. Importarea librăriilor necesare

```

import numpy as np
import pandas as pd
import os
import zipfile
import glob
import seaborn as sns
import matplotlib as mpl
import matplotlib.pyplot as plt
import datetime

```

b. Importarea fișierelor de tip csv în python

```
df_aisle=pd.read_csv('aisles.csv')
df_departments=pd.read_csv('departments.csv')
df_products=pd.read_csv('products.csv')
df_prior_order=pd.read_csv('order_products__prior.csv')
df_orders=pd.read_csv('orders.csv')
```

2) Prelucrarea datelor

a. Îmbinarea tuturor tabelelor într-unul

```
order=pd.merge(df_orders,df_prior_order, on='order_id')
product=pd.merge(df_products,order, on='product_id')
department=pd.merge(product,df_departments,on='department_id')
table=pd.merge(department,df_aisle, on='aisle_id')
```

	product_id	product_name	aisle_id	department_id	order_id	user_id	eval_set	order_number	order_dow	order_hour_of_day	days_since_prior_order	add_to_cart_order	reordered	department	aisle
0	1	Chocolate Sandwich Cookies	61	19	19989	4122	prior	11	2	7	8.0	1	0	snacks	cookies cakes
1	1	Chocolate Sandwich Cookies	61	19	49629	11119	prior	18	1	14	30.0	1	0	snacks	cookies cakes
2	1	Chocolate Sandwich Cookies	61	19	52768	21054	prior	3	1	10	30.0	1	1	snacks	cookies cakes
3	1	Chocolate Sandwich Cookies	61	19	38944	22561	prior	4	6	21	23.0	6	0	snacks	cookies cakes
4	449	Chips Ahoy! Chewy Cookies	61	19	34791	4609	prior	11	4	19	17.0	4	1	snacks	cookies cakes

b. Verificarea numărului de rânduri și coloane din cadrul bazei de date

```
table.shape
```

```
(51000, 15)
```

c. Observarea tipurilor de date ale tabelului

```
table.dtypes
```

```
product_id          int64
product_name        object
aisle_id            int64
department_id        int64
order_id            int64
user_id             int64
eval_set            object
order_number         int64
order_dow           int64
order_hour_of_day    int64
days_since_prior_order float64
add_to_cart_order    int64
reordered           int64
department          object
aisle               object
```

d. Observarea numărului de departamente și numărului de clienți

```
table['departament'].unique()
```

```
array(['produce', 'frozen', 'breakfast', 'dry goods pasta', 'dairy eggs',  
      'snacks', 'meat seafood', 'canned goods', 'deli', 'beverages',  
      'pantry', 'personal care', 'household', 'international', 'bakery',  
      'babies', 'missing', 'other', 'alcohol', 'pets'], dtype=object)
```

```
table['id_cumparator'].nunique()
```

4650

d. Identificarea valorilor ce lipsesc și stergerea acestora

<code>table.isna().sum()</code>		<code>table['days_since_prior_order'].dropna()</code>
product_id	0	8439 30.0
product_name	0	47492 15.0
aisle_id	0	7169 30.0
department_id	0	65283 10.0
order_id	0	25491 8.0
user_id	0	...
eval_set	0	27366 7.0
order_number	0	13649 3.0
order_dow	0	23164 8.0
order_hour_of_day	0	86 3.0
days_since_prior_order	4773	71731 11.0
add_to_cart_order	0	Name: days_since_prior_order, Length: 46227, dtype: float64
reordered	0	
department	0	
aisle	0	

3) Filtrarea bazei de date

a. Sortarea tabelului după numărul comenzii

```
table.sort_values(by=['order_number'], ascending=True, inplace=True)  
table
```

product_id	product_name	aisle_id	department_id	order_id	user_id	eval_set	order_number	order_dow	order_hour_of_day	days_since_prior_order	add_to_cart_order	reordered	department	aisle
39475	Total Greek Strained Yogurt	120	16	46907	14505	prior	1	1	11	NaN	14	0	dairy eggs	yogurt
8518	Organic Red Onion	83	4	9309	12477	prior	1	4	17	NaN	17	0	produce	fresh vegetables
13249	Skim Milk	84	16	1838	18244	prior	1	3	14	NaN	7	0	dairy eggs	milk
12341	Hass Avocados	32	4	26949	8579	prior	1	1	19	NaN	10	0	produce	packaged produce
31915	Organic Red Delicious Apple	24	4	3299	8967	prior	1	0	20	NaN	10	0	produce	fresh fruits
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
16185	Sharp Cheddar Cheese	21	16	19149	10934	prior	99	5	12	6.0	9	1	dairy eggs	packaged cheese
25613	Homestyle Popcorn	23	19	19149	10934	prior	99	5	12	6.0	12	1	snacks	popcorn jerky
38693	Meyer Lemon	24	4	19149	10934	prior	99	5	12	6.0	3	1	produce	fresh fruits
14828	Select Cashews Almonds & Pecans Mixed Nuts	117	19	19149	10934	prior	99	5	12	6.0	10	1	snacks	nuts seeds dried fruit
22920	Roasted & Salted Shelled Pistachios	117	19	19149	10934	prior	99	5	12	6.0	11	0	snacks	nuts seeds dried fruit

b. Ștergerea coloanelor care nu sunt în scopul analizei și redenumirea coloanelor din tabel

```
table.drop(['aisle_id', 'department_id', 'days_since_prior_order', 'eval_set'], axis=1, inplace=True)
```

product_id	product_name	order_id	user_id	order_number	order_dow	order_hour_of_day	add_to_cart_order	reordered	department	aisle
39475	Total Greek Strained Yogurt	46907	14505	1	1	11	14	0	dairy eggs	yogurt
8518	Organic Red Onion	9309	12477	1	4	17	17	0	produce	fresh vegetables
13249	Skim Milk	1838	18244	1	3	14	7	0	dairy eggs	milk
12341	Hass Avocados	26949	8579	1	1	19	10	0	produce	packaged produce
31915	Organic Red Delicious Apple	3299	8967	1	0	20	10	0	produce	fresh fruits

```
table.rename(columns = {'product_id':'id_produș', 'product_name':'nume_produș','aisle':'tip_produș','order_id':'id_comanda',  
                        'user_id':'id_cumparator','order_number':'nr_comanda','order_dow':'zi','order_hour_of_day':'ora',  
                        'department':'departament','reordered':'comandat_din_nou','add_to_cart_order':'ordine_produș_adaugat'}, inplace = True)
```

id_produș	nume_produș	id_comanda	id_cumparator	nr_comanda	zi	ora	ordine_produș_adaugat	comandat_din_nou	departament	tip_produș
39475	Total Greek Strained Yogurt	46907	14505	1	1	11	14	0	dairy eggs	yogurt
8518	Organic Red Onion	9309	12477	1	4	17	17	0	produce	fresh vegetables
13249	Skim Milk	1838	18244	1	3	14	7	0	dairy eggs	milk
12341	Hass Avocados	26949	8579	1	1	19	10	0	produce	packaged produce
31915	Organic Red Delicious Apple	3299	8967	1	0	20	10	0	produce	fresh fruits

c. Transformarea coloanei “zi” din tipul integer în tipul string și înlăturarea cifrelor cu numele fiecărei zi din săptămână

```
table['zi']=table['zi'].astype(str)  
table['zi']=table['zi'].replace('0','Sambata')  
table['zi']=table['zi'].str.replace('1','Duminica')  
table['zi']=table['zi'].replace('2','Luni')  
table['zi']=table['zi'].replace('3','Marti')  
table['zi']=table['zi'].replace('4','Miercuri')  
table['zi']=table['zi'].replace('5','Joi')  
table['zi']=table['zi'].replace('6','Vineri')
```

id_produș	nume_produș	id_comanda	id_cumparator	nr_comanda	zi	ora	ordine_produș_adaugat	comandat_din_nou	departament	tip_produș
39475	Total Greek Strained Yogurt	46907	14505	1	Duminica	11	14	0	dairy eggs	yogurt
8518	Organic Red Onion	9309	12477	1	Miercuri	17	17	0	produce	fresh vegetables
13249	Skim Milk	1838	18244	1	Marti	14	7	0	dairy eggs	milk
12341	Hass Avocados	26949	8579	1	Duminica	19	10	0	produce	packaged produce
31915	Organic Red Delicious Apple	3299	8967	1	Sambata	20	10	0	produce	fresh fruits


d. Transformarea coloanei “ora” din tipul integer în formatul datetime

```
hour_nums = list(range(24))  
hours_of_day = {hour_num:datetime.time(hour_num).strftime("%I:00 %p") for hour_num in hour_nums}  
table['ora'] = table['ora'].replace(to_replace=hours_of_day, value=None)  
table['ora'] = pd.Categorical(table['ora'],  
                             ordered=True,  
                             categories=list(hours_of_day.values()))
```

id_produs	nume_produs	id_comanda	id_cumparator	nr_comanda	zi	ora	ordine_produs_adaugat	comandat_din_nou	departament	tip_produs
39475	Total Greek Strained Yogurt	46907	14505	1	Duminica	11:00 AM	14	0	dairy eggs	yogurt
8518	Organic Red Onion	9309	12477	1	Miercuri	05:00 PM	17	0	produce	fresh vegetables
13249	Skim Milk	1838	18244	1	Marti	02:00 PM	7	0	dairy eggs	milk
12341	Hass Avocados	26949	8579	1	Duminica	07:00 PM	10	0	produce	packaged produce
31915	Organic Red Delicious Apple	3299	8967	1	Sambata	08:00 PM	10	0	produce	fresh fruits

2.4 Analiza și vizualizarea datelor


a. Frecvența absolută a comenzilor în funcție de departament



Grafic 2.1 Frecvența produselor în funcție de departament; Anexa 1

Conform graficului se poate observa că cel mai important departament al magazinului este cel de fructe și legume cu peste 14.000 comenzi. După care este urmat de lactate cu peste 8000 de comenzi și gustările cu aproximativ 4000 comenzi.


b. Frecvența produselor comandate din nou



Grafic 2.2 Frecvența produselor comandate din nou; Anexa 2


În conformitate cu graficul se poate distinge faptul că aproximativ 51% din produsele oferite de magazin au satisfăcut clienții și i-a determinat să le comande din nou.

c. Efectul zilelor asupra comportamentului consumatorului



Grafic 2.3 Efectul zilelor asupra comportamentului consumatorului; Anexa 3


După cum ne sugerează și graficul, cea mai populară zi de cumpărături este sâmbăta unde numărul de comenzi a fost de aproape 9908 comenzi, fiind urmată de duminica care a înregistrat 9125 de comenzi. Cum a fost demonstrat și prin literatura de specialitate, cea mai profitabilă zi pentru un supermarket este sâmbăta, atunci când oamenii au timp liber și își fac cumpărăturile pentru întreaga săptămână.



Grafic 2.4 Cele mai populare departamente în funcție de zi; Power Bi



După cum este ilustrat și în graficul de tip bar chart, se poate observa că marți comparativ cu luni, publicul preferă băuturile răcoritoare, iar vineri comparativ cu joi, lactatele sunt mult mai populare. De asemenea, în pofida faptului că sâmbăta este cea mai populară zi a săptămânii, se pare că duminica departamentul de gustări este mai vizitat. Miercuri însă este cea mai puțin profitabilă zi pentru magazin.


d. Efectul orelor asupra comportamentului consumatorului



Grafic 2.5 Efectul orelor asupra comportamentului consumatorului; Anexa 4

Graficul ne demonstrează un tipar foarte interesant și anume faptul că utilizatorii magazinului au preferat intervalul între ora 12 și 15 pentru a-și efectua cumpărăturile. Acest fenomen este explicat și în statistica făcută de Google Maps, prin care se demonstrează faptul că cea mai aglomerată perioadă de cumpărături este sâmbăta între orele 12-15.






Grafice 2.6 Analiza produselor cumpărate în dependență de perioada zilei; Power Bi

Urmărind cele trei grafice se poate observa faptul că dimineața între orele 6 și 11 oamenii tind să cumpere mai multe fructe, pâine și produse de lactate(cele mai populare fiind laptele și iaurtul). Comparativ cu dimineața, la prânz cumpărătorii preferă cel mai mult legumele și brânzeturile. Pe de altă parte, seara cele mai populare tipuri de produse sunt bucatele și produsele congelate.

e. Topul celor mai cumpărate produse




Grafic 2.7 Topul celor mai cumpărate produse ale magazinului; Anexa 5

După cum se poate regăsi și în grafic, cel mai popular și profitabil produs sunt bananele, care se regăsesc în aproximativ 760 de tranzacții ale magazinului, fiind urmate de căpșuni, baby spanac și

avocado. De asemenea se poate observa că utilizatorii preferă produsele bio peste cele fără denumirea “organic” în față. Pe lângă fructe și legume se poate observa o cerere mare pentru lapte, care apare în peste 200 de tranzacții și humus care apare în mai mult de 100 de tranzacții.

f. Topul produselor adăugate primele în coș



Grafic 2.7 Produse plasate primele în coș; Anexa 6

Conform celor menționate mai sus, bananele sunt cele mai apreciate produse ale magazinului, fiind și primele produse adăugate în coș cu o probabilitate de 3,5%. Acestea sunt urmate de căpșuni și lapte cu o probabilitate mare de a fi adăugate în coș primele.

2.5 Aplicarea algoritmului de asociere Apriori

a) Importarea librăriilor necesare pentru aplicarea algoritmului

```
from mlxtend.frequent_patterns import apriori
from mlxtend.frequent_patterns import association_rules
```

b) Stabilirea frecvenței produsului în dependență de numărul de comenzi în care apare

```
produse_count = table.groupby('id_produs')['id_comanda'].count().reset_index().rename(columns = {'id_comanda': 'frecventa'})
produse_count = produse_count.sort_values('frecventa', ascending=False)[0:100].reset_index(drop=True)
produse_count.head(10)
```

	id_produs	frecventa
0	24852	765
1	13176	556
2	21137	444
3	21903	374
4	47209	348
5	47766	294
6	47626	220
7	16797	220
8	26209	214
9	27966	198

c) Crearea unui tabel pivot compus din numele produsului și id_comandă, cu valori cuprinse între 0 și 1, unde 1 înseamnă că produsul a fost adăugat în aceeași comandă alături de celelalte produse cu valoarea 1.

```
freq_products = list(produse_count.id_produs)
df1 = table[table.id_produs.isin(freq_products)]
basket = df1.pivot_table(columns='nume_produs', values='comandat_din_nou', index='id_comanda').reset_index().fillna(0).set_index('id_comanda')
```

```
#transformăm toate valorile pozitive în 1 și valorile negative în 0
def transf_val(x):
    if x<= 0:
        return 0
    if x>= 1:
        return 1
basket_set = basket.applymap(transf_val)
basket_set
```

nume_produs	100% Raw Coconut Water	100% Whole Wheat Bread	Apple Honeycrisp Organic	Asparagus	Bag of Organic Bananas	Banana	Bartlett Pears	Blueberries	Boneless Skinless Chicken Breasts	Broccoli Crown	...	Sparkling Natural Mineral Water	Sparkling Water Grapefruit	Spring Water	Strawberries	Total Greek Strained Yogurt	Uncured Genoa Salami	Unsweetened Almondmilk	Unsweetened Original Almond Breeze Almond Milk	Vanilla Almond Breeze Almond Milk	Yellow Onions
id_comanda																					
46	0	1	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
52	0	0	0	0	0	1	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
61	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0

d) Stabilirea coeficienților de suport și de încredere o dată cu aplicarea algoritmului

Stabilirea coeficienților s-a făcut pe baza apariției unui număr optim de reguli în conformitate cu mărimea bazei de date.

```
set_produce_frecvente= apriori(basket_set, min_support=0.01, use_colnames=True)
reguli= association_rules(set_produce_frecvente,metric="lift", min_threshold=1)
reguli
```

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	leverage	conviction
0	(Organic Baby Spinach)	(Bag of Organic Bananas)	0.075204	0.115804	0.015259	0.202899	1.752089	0.006550	1.109264
1	(Bag of Organic Bananas)	(Organic Baby Spinach)	0.115804	0.075204	0.015259	0.131765	1.752089	0.006550	1.065144
2	(Organic Hass Avocado)	(Bag of Organic Bananas)	0.074659	0.115804	0.015259	0.204380	1.764878	0.006613	1.111329
3	(Bag of Organic Bananas)	(Organic Hass Avocado)	0.115804	0.074659	0.015259	0.131765	1.764878	0.006613	1.065772
4	(Organic Strawberries)	(Bag of Organic Bananas)	0.086649	0.115804	0.014986	0.172956	1.493526	0.004952	1.069104
5	(Bag of Organic Bananas)	(Organic Strawberries)	0.115804	0.086649	0.014986	0.129412	1.493526	0.004952	1.049120
6	(Banana)	(Large Lemon)	0.162943	0.034060	0.010627	0.065217	1.914783	0.005077	1.033331
7	(Large Lemon)	(Banana)	0.034060	0.162943	0.010627	0.312000	1.914783	0.005077	1.216653
8	(Organic Avocado)	(Banana)	0.053678	0.162943	0.016349	0.304569	1.869175	0.007602	1.203652
9	(Banana)	(Organic Avocado)	0.162943	0.053678	0.016349	0.100334	1.869175	0.007602	1.051859
10	(Organic Baby Spinach)	(Banana)	0.075204	0.162943	0.016894	0.224638	1.378629	0.004640	1.079569
11	(Banana)	(Organic Baby Spinach)	0.162943	0.075204	0.016894	0.103679	1.378629	0.004640	1.031768
12	(Banana)	(Organic Strawberries)	0.162943	0.086649	0.017166	0.105351	1.215845	0.003047	1.020905
13	(Organic Strawberries)	(Banana)	0.086649	0.162943	0.017166	0.198113	1.215845	0.003047	1.043860
14	(Organic Baby Spinach)	(Organic Hass Avocado)	0.075204	0.074659	0.013351	0.177536	2.377949	0.007737	1.125084
15	(Organic Hass Avocado)	(Organic Baby Spinach)	0.074659	0.075204	0.013351	0.178832	2.377949	0.007737	1.126196
16	(Organic Baby Spinach)	(Organic Strawberries)	0.075204	0.086649	0.011172	0.148551	1.714406	0.004655	1.072702
17	(Organic Strawberries)	(Organic Baby Spinach)	0.086649	0.075204	0.011172	0.128931	1.714406	0.004655	1.061679
18	(Organic Hass Avocado)	(Organic Strawberries)	0.074659	0.086649	0.013624	0.182482	2.106000	0.007155	1.117225
19	(Organic Strawberries)	(Organic Hass Avocado)	0.086649	0.074659	0.013624	0.157233	2.106000	0.007155	1.097979

e) Sortarea regulilor după importanța acestora

```
#Sortare reguli dupa relevanta lor
reguli.sort_values(['lift'], ascending=False, inplace=True)
reguli
```

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	leverage	conviction
14	(Organic Baby Spinach)	(Organic Hass Avocado)	0.075204	0.074659	0.013351	0.177536	2.377949	0.007737	1.125084
15	(Organic Hass Avocado)	(Organic Baby Spinach)	0.074659	0.075204	0.013351	0.178832	2.377949	0.007737	1.126196
19	(Organic Strawberries)	(Organic Hass Avocado)	0.086649	0.074659	0.013624	0.157233	2.106000	0.007155	1.097979
18	(Organic Hass Avocado)	(Organic Strawberries)	0.074659	0.086649	0.013624	0.182482	2.106000	0.007155	1.117225
6	(Banana)	(Large Lemon)	0.162943	0.034060	0.010627	0.065217	1.914783	0.005077	1.033331
7	(Large Lemon)	(Banana)	0.034060	0.162943	0.010627	0.312000	1.914783	0.005077	1.216653
9	(Banana)	(Organic Avocado)	0.162943	0.053678	0.016349	0.100334	1.869175	0.007602	1.051859
8	(Organic Avocado)	(Banana)	0.053678	0.162943	0.016349	0.304569	1.869175	0.007602	1.203652
2	(Organic Hass Avocado)	(Bag of Organic Bananas)	0.074659	0.115804	0.015259	0.204380	1.764878	0.006613	1.111329
3	(Bag of Organic Bananas)	(Organic Hass Avocado)	0.115804	0.074659	0.015259	0.131765	1.764878	0.006613	1.065772
0	(Organic Baby Spinach)	(Bag of Organic Bananas)	0.075204	0.115804	0.015259	0.202899	1.752089	0.006550	1.109264
1	(Bag of Organic Bananas)	(Organic Baby Spinach)	0.115804	0.075204	0.015259	0.131765	1.752089	0.006550	1.065144
17	(Organic Strawberries)	(Organic Baby Spinach)	0.086649	0.075204	0.011172	0.128931	1.714406	0.004655	1.061679
16	(Organic Baby Spinach)	(Organic Strawberries)	0.075204	0.086649	0.011172	0.148551	1.714406	0.004655	1.072702
5	(Bag of Organic Bananas)	(Organic Strawberries)	0.115804	0.086649	0.014986	0.129412	1.493526	0.004952	1.049120
4	(Organic Strawberries)	(Bag of Organic Bananas)	0.086649	0.115804	0.014986	0.172956	1.493526	0.004952	1.069104
11	(Banana)	(Organic Baby Spinach)	0.162943	0.075204	0.016894	0.103679	1.378629	0.004640	1.031768
10	(Organic Baby Spinach)	(Banana)	0.075204	0.162943	0.016894	0.224638	1.378629	0.004640	1.079569
12	(Banana)	(Organic Strawberries)	0.162943	0.086649	0.017166	0.105351	1.215845	0.003047	1.020905
13	(Organic Strawberries)	(Banana)	0.086649	0.162943	0.017166	0.198113	1.215845	0.003047	1.043860

În urma utilizării algoritmului Apriori se pot extrage următoarele reguli valide coșului de cumpărături:

Regula 1: Dacă o persoană va cumpăra **spanac**, atunci există o probabilitate mare ca acesta să cumpere și **avocado**.

Regula 2: Dacă o persoană va cumpăra **căpșuni**, atunci există o probabilitate mare ca acesta să cumpere și **avocado**.

Regula 3: Dacă o persoană va cumpăra **banane**, atunci există o probabilitate mare ca acesta să cumpere și **lămâi**.

Regula 4: Dacă o persoană va cumpăra **avocado**, atunci există o probabilitate mare ca acesta să cumpere și **banane**.

Regula 5: Dacă o persoană va cumpăra **spanac**, atunci există o probabilitate mare ca acesta să cumpere și **banane**.

Regula 6: Dacă o persoană va cumpăra **căpșuni**, atunci există o probabilitate mare ca acesta să cumpere și **banane**.

2.6 Concluzii privind studiul de caz

În urma studiului de caz am observat câteva aspecte interesante în comportamentul consumatorului și diferite metode creative de a crește cifra de afaceri a magazinului. În primul rând, venitul supermarketului se bazează pe vânzarea de fructe și legume, produse de lactate, ouă și gustări. De asemenea managerii ar trebui să se focuseze mai puțin pe vânzarea de crupe (întâlnite sub denumirea de “Bulk”) și pe vânzarea de alcool. În același timp este recomandat să crească producția de fructe, legume și produse organice. Un alt aspect important în analiza tranzacțiilor este perioada cea mai aglomerată a magazinului. Astfel sâmbăta, între orele 12 și 15 managerii trebuie să se asigure că magazinul este suficient de aprovizionat, pentru a satisface fluxul de oameni prognozat pentru acea perioadă. Pe lângă aceasta, marți magazinul ar trebui să aibă suficiente produse la vedere din categoria băuturilor răcoritoare, joi este preferabil ca departamentul de lactate să fie aprovizionat, iar duminica să se producă cât mai multe gustări și produse de panificație. Mai mult de atât, miercuri majoritatea personalului poate fi eliberat, magazinul fiind mai gol în acea perioadă, pe când în weekend este de preferat să fie cât mai multe resurse umane. Alt aspect important ce ține de preferințele consumatorilor în dependență de oră este faptul că dimineața cele mai solicitate sunt produsele de panificație, lactatele (în special laptele și iaurtul) și fructele, iar la prânz cumpărătorii preferă legumele și brânzeturile. Seara cele mai populare tipuri de produse sunt bucatele și produsele congelate (în special carnea, înghețata și pizza congelată). Conform graficului 10 cel mai profitabil produs al magazinului sunt bananele, urmate de căpșuni, baby spanac și lapte, fiind și produsele care atrag primele ochiul consumatorului.

Pe baza analizei coșului de cumpărături cu ajutorul algoritmului de asociere Apriori, s-a stabilit faptul că produsele cumpărate frecvent împreună sunt: spanacul și avocado, căpșunile și avocado, lămâile și bananele, avocado și bananele și căpșunele și bananele. Astfel, pentru a crește profitul din vânzări managerii ar trebui să promoveze aceste produse împreună, sau să le poziționeze în aceeași vecinătate.

Concluzii

O dată cu apariția fenomenului de Big Data, inteligența artificială a început să fie din ce în ce mai integrată în rândul companiilor mari precum Amazon, Netflix, Spotify și Meta. Un rol important în rândul instrumentelor de decizie din cadrul inteligenței artificiale îl are analiza coșului de cumpărături, sau market basket analysis. Această tehnică de asociere presupune descoperirea combinațiilor de produse cumpărate frecvent împreună și este aplicată direct asupra istoricului tranzacțiilor făcute de consumatori. Motivul pentru care această metodă a devenit vitală se datorează exactității datelor și formării unei decizii pe baza calculelor statistice și matematice, și nu pe baza intuiției analiștilor. Așadar, market basket analysis poate fi aplicat în cross-selling, marketing și promoții țintite pe captarea atenției clienților.

În urma realizării studiului de caz, unde am folosit baza de date a unui magazin cu peste 50.000 de tranzacții am descoperit câteva aspecte importante în ceea ce privește comportamentul consumatorului. În primul rând, cea mai profitabilă perioadă a săptămânii pentru un magazin este ziua de sâmbătă în intervalul de ore 12 – 15, pe de altă parte cea mai puțin aglomerată zi este miercuri.²³ De asemenea, am constatat faptul că dimineața consumatorii preferă fructele, laptele, iaurtul și produsele de panificație, pe când seara, este o tendință mai mare pentru produsele congelate cum ar fi: pizza, carnea și înghețata.²⁴ S-a demonstrat că cel mai profitabil produs sunt bananele datorită faptului că sunt ușor de utilizat, sunt ieftine și pe gustul tuturor. Mai mult de atât, conform graficului 2.7²⁵, bananele, căpșunile și laptele sunt primele produse care sunt puse în coș de către cumpărători. Un alt aspect interesant sunt produsele cumpărate frecvent împreună. În cadrul studiului am constatat faptul că utilizatorii magazinului tind să cumpere următoarele combinații de produse: spanacul și avocado, căpșunile și avocado, lămâile și bananele, avocado și bananele și căpșunele și bananele.²⁷

Câteva limitări în ceea ce privește analiza coșului de cumpărături ar fi: lipsa datelor esențiale din cadrul bazei de date, experiența redusă a analistului financiar și interpretarea greșită a rezultatelor și parcurgerea lentă a bazelor de date enorme de către algoritm.³⁰

Cu toate acestea, analiza coșului de cumpărături a devenit o practică esențială în înțelegerea comportamentului consumatorului și oferă date utile managementului în vederea creșterii profitului prin campaniile potrivite de marketing, maximizării profitului prin focusarea pe produselor populare,

³⁰ Association rules in data mining / Zayko T.A., Oliinyk A.A., Subbotin S.A. // Herald of the National University "KhPI". Subject issue: Information science and Modeling. – Kharkov: NTU "KhPI". – 2013. – № 39 (1012). – C. 82– 96.

gestionării resurselor umane conform perioadelor aglomerate în magazin și previzionarea mai exactă a deciziilor cumpărătorilor.

Bibliografie

1. Statista. 2022. [online] Available at: <https://www.statista.com/statistics/278414/number-of-worldwide-social-network-users/>
2. Statista. 2022. [online] Available at: <https://www.statista.com/statistics/871513/worldwide-data-created/>
3. Hartmann, P. M., Zaki, M., Feldmann, N., & Neely, A. (2014). Big data for big business? A taxonomy of data-driven business models used by start-up firms. *Cambridge service alliance*, 1-29
4. Linden G, Smith B, York J. Amazon.com recommendation: item-to-item collaborative filtering. *IEEE Internet Comput* 2003;7(1):76–80
5. Winston, P. H. (1984). *Artificial intelligence*. Addison-Wesley Longman Publishing Co., Inc..
6. Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of management information systems*, 24(3), 45-77.
7. <https://dexonline.ro/definitie/decizie>
8. Fishburn, P. C. (1989). Foundations of decision analysis: along the way. *Management science*, 35(4), 387-405.
9. Kourteli, L. (2000). Scanning the business environment: some conceptual issues. *Benchmarking: An international journal*.
10. Power, D. J. (2002). *Decision support systems: concepts and resources for managers*. Greenwood Publishing Group.
11. Jordan, M. I., & Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245), 255-260.
12. Michalski, R. S., Carbonell, J. G., & Mitchell, T. M. (Eds.). (2013). *Machine learning: An artificial intelligence approach*. Springer Science & Business Media.
13. C. M. Bishop, *Neural Networks for Statistical Pattern Recognition* (1994), Oxford University Press, Oxford.
14. Laurence Moroney. (2020). *AI and Machine Learning for Coders*. Sebastopol: Gravenstein Highway North.
15. Agrawal R, Imieliński T, Swami A. Mining association rules between sets of items in large databases. In: *ACM SIGMOD Record*. ACM. 1993;22: 207–216
16. Zhang C. *Association rule mining: models and algorithms* / C. Zhang, S. Zhang. – Berlin: Springer-Verlag. – 2002. – 238 p.

17. Ke Y. An information-theoretic approach to quantitative association rule mining / Y. Ke, J. Cheng, N. Wilfred // Knowledge and Information Systems. – 2008. – Vol. 16. – № 2. – P. 213-244.
18. Bob Violino. Machine learning: When to use each method and technique. InfoWorld. SEP 6, 2018
19. Thaler, R. H. (2015). Misbehaving: The making of behavioral economics. W W Norton & Co.
20. Tversky, A., & Kahneman, D. (1974). Judgment under Uncertainty: Heuristics and Biases. Science, 185(4157), 1124–1131. <http://www.jstor.org/stable/1738360>
21. Anderson, P. (1986). Personality, perceptions and emotion-state factors in approach-avoidance behaviors in the store environment. In Terence A. Shimp et al. (Eds.), 1986 AMA educators' proceedings (pp. 35–39). Chicago: American Marketing Association.
22. Wesley J. Johnston (1981), "Time and Consumer Behavior", in NA - Advances in Consumer Research Volume 08, eds. Kent B. Monroe, Ann Arbor, MI : Association for Consumer Research
23. Google Maps. 2020. [online] Available at: <https://blog.google/products/maps/2020holiday-trends-google-maps/>
24. Journal of Consumer Research, Volume 46, Issue 1, June 2019, Pages 20–35, <https://doi.org/10.1093/jcr/ucy061>
25. Koeppe, D. (2008). Banana: The fate of the fruit that changed the world. New York: Hudson Street Press
26. U.S. Bureau of Labour Statistics. 2022. [online] Available at: https://www.bls.gov/cpi/questions-and-answers.htm#Question_6
27. Sheldon Bosio, A. (2015). "Examining consumer preferences within the avocado industry: does point of origin matter?". Unpublished doctoral dissertation, California Polytechnic State University, California
28. Borrero, Juan D., and Alberto Zabalo. 2021. "Identification and Analysis of Strawberries' Consumer Opinions on Twitter for Marketing Purposes" Agronomy 11, no. 4: 809. <https://doi.org/10.3390/agronomy11040809>
29. "The Instacart Online Grocery Shopping Dataset 2017", Accessed from <https://www.instacart.com/datasets/grocery-shopping-2017> on 30.05.2022
30. Association rules in data mining / Zayko T.A., Oliinyk A.A., Subbotin S.A. // Herald of the National University "KhPI". Subject issue: Information science and Modeling. – Kharkov: NTU "KhPI". – 2013. – № 39 (1012). – C. 82– 96.

Anexe

1.

```
import matplotlib.pyplot as plt
frecventa_abs=(table['departament'].value_counts())
plt.rcParams['figure.figsize']=(9,6)
plt.title('Frecvența comenzilor în funcție de departament',fontsize=14)
plt.xticks(rotation=35,fontsize=12)
plt.ylabel('Frecvența absolută',fontsize=12)
frecventa_abs.plot(kind='bar',color=(0.5, 0.8, 0.1, 0.2), edgecolor='black')
```

2.

```
comandat0=table['comandat_din_nou'].replace(0,'Nu')
comandat=comandat0.replace(1,'Da')
total_prod_comandate = table.shape[0]
procent_produce_recomandate = comandat.value_counts()/total_prod_comandate
procent = pd.DataFrame(procent_produce_recomandate)
comandat0=table['comandat_din_nou'].replace(0,'Nu')
comandat=comandat0.replace(1,'Da')
total_prod_comandate = table.shape[0]
procent_produce_recomandate = comandat.value_counts()/total_prod_comandate
plt.rcParams['figure.figsize']=(9,6)
plt.title('Frecvența produselor comandate din nou',fontsize=14)
plt.xticks(rotation=30,fontsize=12)
plt.xlabel('Comandate din nou',fontsize=12)
plt.ylabel('Procent',fontsize=12)
procent_produce_recomandate.plot(kind='bar',color=(0.5, 0.8, 0.1, 0.2), edgecolor='black')
```

3.

```
import seaborn as sns
sns.set_palette(sns.color_palette("Set2"))
ax=sns.histplot(data=table, x='zi',bins=7)
plt.xlabel('zile')
plt.ylabel('Număr din comenzi')
plt.title('Popularitate comenzi în dependență de zi')
plt.xticks(rotation= 45)
for p in ax.patches:
    height = p.get_height()
    ax.text(x = p.get_x()+(p.get_width()/2), y = height+ 2, s = '{:.0f}'.format(height), ha = 'center')
plt.show()
```

4.

```
sns.set_palette(sns.color_palette("ch:start=.2,rot=-.3"))
ax=sns.histplot(data=table, x='ora',bins=24)
plt.xlabel('ore')
plt.ylabel('Total comenzi')
plt.title('Popularitate comenzi în dependență de oră')
plt.xticks(rotation= 90)
plt.show()
```

5.

```
#Top 30 cele mai cumparate produse
ax = sns.countplot(y=table['nume_produș'], order=table['nume_produș'].value_counts().iloc[:30].index, palette='mako')
ax.tick_params(axis='y', length=0)
plt.xlabel('Frecvența absolută')
plt.ylabel('Nume produș')
plt.title('Top 30 cele mai cumpărate produse')
plt.tight_layout()
plt.show()
```

6.

```
#Top 30 produse adaugate primele in coș
total_comenzi = table['id_comanda'].nunique()
# Sortare produș după nr de ori adaugat în coș
primul_produș_comandat = table[table['ordine_produș_adaugat'] == 1]
primul_produș_frecv_desc = primul_produș_comandat.groupby(['nume_produș'], as_index = False)
['id_comanda'].count().sort_values(by=['id_comanda'], ascending=False)
primul_produș_frecv_desc['count_of_ordering_first'] = primul_produș_frecv_desc['id_comanda']
primul_produș_frecv_desc['probabilitate_de_a_fi_cumpărat_primul']
= (primul_produș_frecv_desc['count_of_ordering_first']/total_comenzi)* 100
sns.set_palette(sns.color_palette("icefire"))
primul_produș_frecv_desc.iloc[:30].plot.bar(x='nume_produș', y='probabilitate_de_a_fi_cumpărat_primul')
plt.ylabel('probabilitatea produșului de a fi cumpărat primul')
plt.xlabel('denumire produș')
plt.xticks(rotation=90)
plt.title('Top 20 produse puse primele în coș')
plt.show()
```